```
import time
import warnings
from tqdm.notebook import tqdm
from collections import defaultdict
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from catboost import CatBoostRanker, Pool, MetricVisualizer
from copy import deepcopy

import pandas as pd
import scipy.stats as sps
```

Тестовое задание

Обзор

data = pd.read_csv('intern_task.csv') Г387... [360... data.head() Out[360]: rank query_id feature_0 feature_1 feature_2 feature_3 feature_4 feature_5 feature_6 feature_7 0 10 1.0 0.0 1.0 3.0 3.0 0.333333 0.0 0.333333 1 1 10 3.0 0.0 3.0 0.0 3.0 1.000000 0.0 1.000000 2 0 10 3.0 0.0 2.0 0.0 3.0 1.000000 0.0 0.666667 3 10 3.0 0.0 3.0 0.0 1.000000 1.000000 3.0 0.0 2 4 10 3.0 0.0 3.0 1.0 3.0 1.000000 0.0 1.000000

5 rows × 146 columns

Out[361]:

In [361... data.describe()

rank feature 2 feature 3 query_id feature 0 feature_1 featu count 235258.000000 235258.000000 235258.000000 235258.000000 235258.000000 235258.000000 235258.000 0.677869 14828.413401 1.911960 0.206233 1.189847 1.960 mean 0.550272 std 0.830033 1.037233 0.790947 1.203 8193.945170 1.237374 0.579089 0.000000 0.000000 0.000000 min 10.000000 0.000000 0.000000 0.000 25% 0.000000 8215.000000 1.000000 0.000000 0.000000 0.000000 1.000 50% 0.000000 14935.000000 2.000000 0.000000 1.000000 0.000000 2.000 75% 1.000000 21580.000000 3.000000 0.000000 2.000000 1.000000 3.000 4.000000 29995.000000 31.000000 18.000000 27.000000 9.000000 31.000 max

8 rows × 146 columns

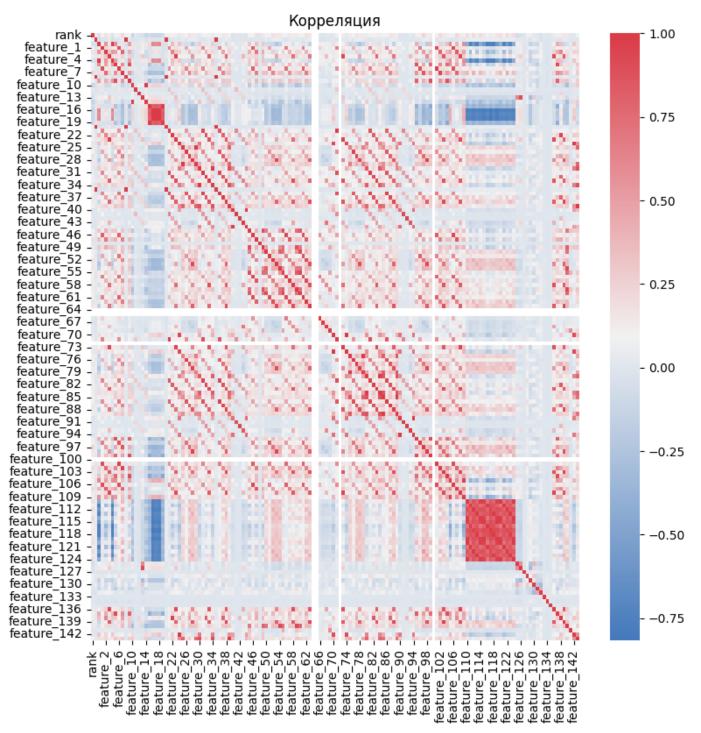
In [362... print(f'Кол-во пропусков: {data.isna().sum()}')

Кол-во пропусков: 0

Анализ фич

В нашем случае, размер выборки не мал. Если размер выборки велик, а распределение признаков не нормальное, то коэффициент корреляции Пирсона выборки остается примерно несмещенным, но может быть неэффективным.

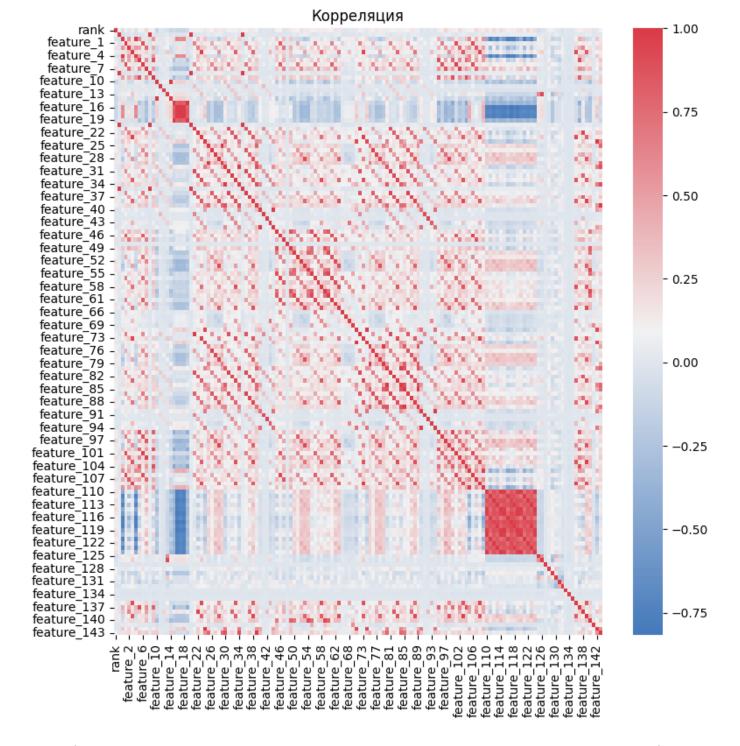
```
In [58]: plt.figure(figsize=(9, 9))
    cmap = sns.diverging_palette(250, 10, as_cmap=True)
    sns.heatmap(data.corr(), cmap=cmap)
    plt.title("Корреляция")
    plt.show()
```



- 1. которые вообще не коррелируют;
- которые сильно коррелируют с некоторыми (может быть линейная зависимость между ними → мультиколлинеарность); Возможно, это одна и та же фича (по смыслу), но в другом формате или представлении

Посмотрим отдельно на них

```
useless_feats = []
In [363...
          for i in range(144):
             feat = f'feature_{i}'
             minn = data[feat].min()
             maxx = data[feat].max()
              if np.isclose(minn, maxx) or data[feat].std() < 0.0001:</pre>
                  useless_feats.append(feat)
                  print(f'Неинформативный признак {feat}: мин. {minn}, макс. {maxx}')
          useless_feats
         Неинформативный признак feature_64: мин. 0, макс. 0
         Неинформативный признак feature_65: мин. 0, макс. 0
         Неинформативный признак feature_72: мин. 1, макс. 1
         Неинформативный признак feature_100: мин. 0, макс. 0
          ['feature_64', 'feature_65', 'feature_72', 'feature_100']
Out[363]:
         Удалим их
         data = data.drop(columns=useless_feats)
In [388...
In [87]:
         plt.figure(figsize=(9, 9))
          cmap = sns.diverging_palette(250, 10, as_cmap=True)
          sns.heatmap(data.corr(), cmap=cmap)
          plt.title("Корреляция")
          plt.show()
```



Попробуем задетектить категориальные признаки. Целочисленных признаков много. Пусть это будут те признаки, у которых всего макс. З значения

```
for feat in data.columns:
    unique_a = np.unique(data[feat])
    if (unique_a.astype(int) == unique_a).sum() == len(unique_a) and len(unique_a) < 4 a
        print(f'Предположительно категориальная {feat} имеет {len(unique_a)} значений {n
        cat_feats.append(feat)

Предположительно категориальная feature_95 имеет 2 значений [0. 1.]
Предположительно категориальная feature_96 имеет 2 значений [0. 1.]
Предположительно категориальная feature_97 имеет 2 значений [0. 1.]
Предположительно категориальная feature_98 имеет 2 значений [0. 1.]
Предположительно категориальная feature_99 имеет 2 значений [0. 1.]
Предположительно категориальная feature_99 имеет 2 значений [0. 1.]
```

Если же нет, то их много

```
In [355... cat_feats = []
          for feat in data.columns:
              unique_a = np.unique(data[feat])
              if (unique_a.astype(int) == unique_a).sum() == len(unique_a) and len(unique_a) < 30</pre>
                   print(f'Предположительно категориальная {feat} имеет {len(unique_a)} значений {n
                   cat_feats.append(feat)
          Предположительно категориальная feature_0 имеет 16 значений [ 0.
                                                                                      2.
                                                                                           3.
                                                                                                   5.
                                                                                                        6.
            7. 8. 9. 10. 11. 24. 26. 27. 31.]
          Предположительно категориальная feature_1 имеет 10 значений [ 0.
                                                                                      2.
                                                                                           3.
                                                                                                   5.
                                                                                                        6.
            7. 9. 18.]
          Предположительно категориальная feature_2 имеет 15 значений [ 0.
                                                                                      2.
                                                                                           3.
                    9. 19. 20. 22. 24. 27.]
          Предположительно категориальная feature_3 имеет 10 значений [0. 1. 2. 3. 4. 5. 6. 7. 8.
          9.]
          Предположительно категориальная feature_4 имеет 16 значений [ 0.
                                                                                      2.
                                                                                           3.
            7. 8. 9. 10. 11. 24. 26. 27. 31.]
          Предположительно категориальная feature_23 имеет 13 значений [ 0.
                                                                                   1.
                                                                                            3.
                                                                                                    5.
          6. 7. 8. 9. 10. 12. 42.]
                                                                                            3.
                                                                                                    5.
          Предположительно категориальная feature_26 имеет 26 значений [ 0.
                                                                                   1.
                                                                                       2.
                                                                                                4.
                  8. 9. 10. 11. 12. 13. 14. 15. 16. 17.
           18. 19. 22. 24. 25. 28. 49. 52.]
          Предположительно категориальная feature_27 имеет 24 значений [
                                                                                           2.
                                                                                                3.
                                                                                                      4.
                                9.
                                    10.
                                         11.
                                               12.
               6.
                     7.
                          8.
                                                    13.
                                  27. 30.
                                            32. 38. 53. 104.]
                 15.
                       21.
                            22.
          Предположительно категориальная feature_28 имеет 10 значений [ 0.
                                                                                                     5.
          6. 10. 12. 42.]
          Предположительно категориальная feature_33 имеет 11 значений [ 0.
                                                                                            3.
                                                                                                     5.
          6. 8. 10. 12. 42.]
          Предположительно категориальная feature_95 имеет 2 значений [0. 1.]
          Предположительно категориальная feature_96 имеет 2 значений [0. 1.]
          Предположительно категориальная feature_97 имеет 2 значений [0. 1.]
          Предположительно категориальная feature_98 имеет 2 значений [0. 1.]
          Предположительно категориальная feature_99 имеет 2 значений [0. 1.]
          Предположительно категориальная feature_125 имеет 19 значений [ 1. 2.
                                                                                        3.
                                                                                                     6.
                  9. 10. 11. 12. 13. 14. 15. 16. 17. 18.
          7. 8.
           31.]
          plt.figure(figsize=(15, 6))
In [318...
          for i in range(10):
              plt.subplot(2, 5, i + 1)
              plt.hist(data[cat_feats[i]], bins=20)
              plt.xlim(0, 11)
                                                150000
                             200000
          120000
                                                                                     120000
                                                                  125000
                                               125000
          100000
                                                                                     100000
                             150000
                                                                  100000
                                                100000
           80000
                                                                                      80000
                                                                   75000
                                                75000
           60000
                             100000
                                                                                      60000
                                                                   50000
                                                50000
           40000
                                                                                      40000
                             50000
                                                                   25000
           20000
                                                25000
                                                                                      20000
                                                                      0
             0 -
                                                   0
                            10
                                               10
                                                                  10
                                                                                     10
                                                                                                       10
          200000
                             200000
                                               200000
                                                                  200000
                                                                                     200000
          150000
                             150000
                                                150000
                                                                  150000
                                                                                     150000
          100000
                             100000
                                                100000
                                                                  100000
                                                                                     100000
           50000
                             50000
                                                50000
                                                                   50000
                                                                                      50000
             0 -
```

Причем у некоторых есть критические значения которых мало. Так как у нас нет описания признаков,

я тоже ничего не буду с ними делать + не уверен что они вообще категориальные

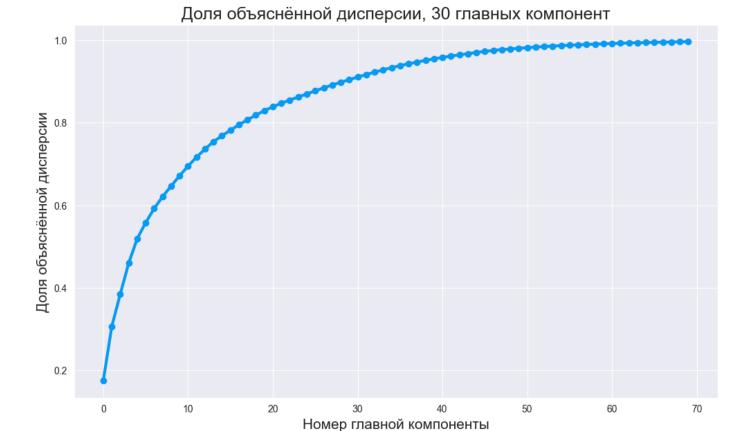
Пока возьмем за категориальные фичи у которых всего 2 значения

```
In [390...
            cat_data = data[cat_feats].astype(int)
            data = data.drop(columns=cat_feats)
            cat_data.describe()
In [394...
                        feature 95
                                       feature 96
                                                      feature 97
                                                                      feature 98
                                                                                     feature_99
Out[394]:
            count 235258.000000 235258.000000
                                                  235258.000000
                                                                  235258.000000
                                                                                 235258.000000
             mean
                         0.699912
                                        0.061779
                                                        0.383192
                                                                       0.184946
                                                                                       0.733046
               std
                         0.458297
                                        0.240754
                                                        0.486166
                                                                       0.388254
                                                                                       0.442369
              min
                         0.000000
                                        0.000000
                                                        0.000000
                                                                       0.000000
                                                                                       0.000000
              25%
                         0.000000
                                        0.000000
                                                        0.000000
                                                                       0.000000
                                                                                       0.000000
              50%
                         1.000000
                                        0.000000
                                                        0.000000
                                                                       0.000000
                                                                                       1.000000
              75%
                         1.000000
                                        0.000000
                                                        1.000000
                                                                       0.000000
                                                                                       1.000000
              max
                         1.000000
                                        1.000000
                                                        1.000000
                                                                       1.000000
                                                                                       1.000000
```

Что касается выбросов (если они есть): Их можно задетектить с помощью Robust Random Cut Forest или других методов. Но так как у нас нет никакого описания признаков, я не буду этого делать.

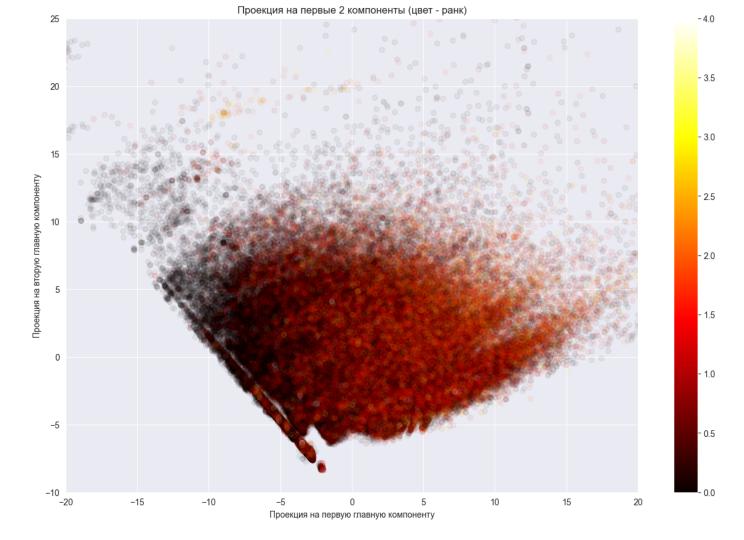
Подход 1: РСА

```
In [395...
         Y_data = data['rank']
         Q_data = data['query_id']
         X_data = data.drop(columns=['rank', 'query_id'])
In [396...
         scaler = StandardScaler()
         scaled_X_data = scaler.fit_transform(X_data)
         pca = PCA(n\_components=70)
In [397...
          pca.fit(scaled_X_data)
Out[397]:
                    PCA
          PCA(n_components=70)
         sns.set_style('darkgrid')
In [371...
         plt.figure(figsize=(12, 7))
         plt.title("Доля объяснённой дисперсии, 30 главных компонент", fontsize=18)
         plt.scatter(np.arange(70), pca.explained_variance_ratio_.cumsum(), color="xkcd:azure");
         plt.plot(np.arange(70), pca.explained_variance_ratio_.cumsum(), color="xkcd:azure", lw=3
         plt.xlabel("Номер главной компоненты", fontsize=15)
         plt.ylabel("Доля объяснённой дисперсии", fontsize=15)
          plt.show()
```



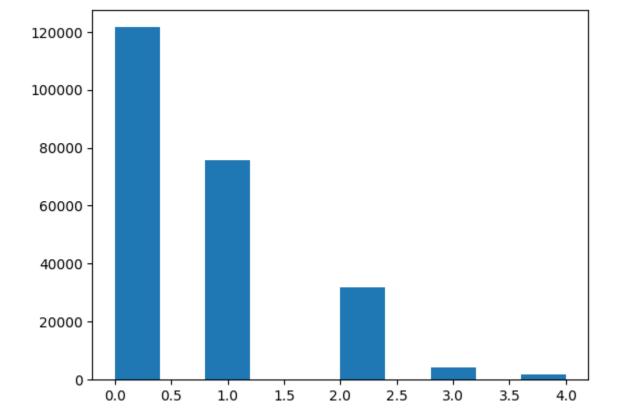
Выберем 30 компонент

```
n_components=30
In [398...
In [399...
         pca = PCA(n_components=n_components)
         scaled_tranformed_X = pca.fit_transform(scaled_X_data)
         pca = PCA(n_components=3)
In [164...
         Y = pca.fit_transform(scaled_X_data)
         plt.figure(figsize=(15, 10))
         p = plt.scatter(Y[:, 0], Y[:, 1], c=Y_data, cmap='hot', alpha=1)
         plt.xlabel('Проекция на первую главную компоненту')
         plt.ylabel('Проекция на вторую главную компоненту')
         plt.title('Проекция на первые 2 компоненты (цвет - ранк)')
         plt.colorbar()
         p.set_alpha(0.05)
         plt.xlim(-20, 20)
         plt.ylim(-10, 25)
         plt.show()
```



Заметно смещение по рангу

Распределение рангов



Подготовка к обучению

In [402...

```
In [400...
          X_df = pd.DataFrame(scaled_tranformed_X)
          X_df = pd.concat([X_df, cat_data], axis=1)
          X_df.head()
                     0
                                        2
                                                  3
                                                                      5
                                                                                         7
                                                                                                   8
Out[400]:
                               1
                                                            4
                                                                               6
               4.052559
                       2.344586
                                 -9.747515 -3.416371
                                                     1.336300 -3.534182
                                                                         0.909853
                                                                                   0.955754
                                                                                           -1.093650
                                                                                                      1.376543
              -0.432786 2.264945
                                                               0.409672
                                  3.081714 -1.804683
                                                    -2.302030
                                                                         0.450202 -1.160240
                                                                                            -0.467964
                                                                                                      0.512443
              -2.645617 1.129820
                                  1.719140 -0.952188
                                                    -1.674765
                                                               0.443441 -0.317642 -1.520690
                                                                                            -0.558013
                                                                                                      0.809746
              -0.452983 1.162849
                                  2.626443 -2.370404 -4.113124
                                                              -1.693650 -0.483230
                                                                                 -1.024103
                                                                                             0.312562 0.223809
               2.739472 3.112070 -1.074635 -3.516672 -2.758475 -0.750276
                                                                         2.074385
                                                                                 -1.620698
                                                                                            -1.663656 1.713078
           5 rows × 35 columns
In [375..
           Q_data.unique().shape
           (2000,)
Out[375]:
          Всего 2000 сессии. На оценку качества отведем 200 (10%).
In [401...
           Q_test_indexes = np.random.choice(Q_data.unique(), size=200, replace=False)
           Q_train_indexes = np.array([i for i in Q_data.unique() if i not in Q_test_indexes])
```

assert(Q_train_indexes.shape[0] == 1800 and Q_test_indexes.shape[0] == 200)

X_train_df = X_df.loc[np.where(Q_data.isin(Q_train_indexes))]

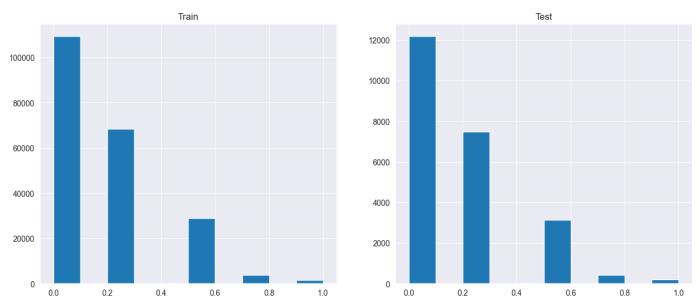
X_test_df = X_df.loc[np.where(Q_data.isin(Q_test_indexes))]

y_train = Y_data.loc[np.where(Q_data.isin(Q_train_indexes))]
y_test = Y_data.loc[np.where(Q_data.isin(Q_test_indexes))]

Убедимся, что распределение классов одинаково

```
In [490... plt.figure(figsize=(15, 6))
    plt.suptitle('Распределение рангов')
    plt.subplot(121)
    plt.title('Train')
    y_train.hist()
    plt.subplot(122)
    plt.title('Test')
    y_test.hist()
    plt.show()
```

Распределение рангов



Они почти совпадают, т.к. мы брали рандомное разбиение

Обучение

CatBoostRanker

Для подсчета метрик отобразим ранги на отрезок [0, 1]

```
In [404... max_rank = np.max(Y_data)
    y_train /= max_rank
    y_test /= max_rank

In [405... train = Pool(
         data=X_train_df,
         label=y_train,
         group_id=Q_train,
         cat_features=np.array(cat_data.columns)
```

```
test = Pool(
             data=X_test_df,
             label=y_test,
             group_id=Q_test,
             cat_features=np.array(cat_data.columns)
In [510...
         params = {
              'iterations': 2000,
              'custom_metric': ['NDCG:top=5', 'NDCG:top=10', 'PFound', 'PrecisionAt:top=5', 'MAP:t
              'verbose': False,
              'random_seed': 42,
         }
         def train_ranker(loss_function, plot=False):
In [511...
             parameters = deepcopy(params)
             parameters['loss_function'] = loss_function
             parameters['train_dir'] = loss_function
             model = CatBoostRanker(**parameters)
             model.fit(train, eval_set=test, plot=plot, use_best_model=True)
             return model.best_score_
         def dict_to_dataframe(metrics_dict, model_name, df=None):
In [527...
             learn_metrics = metrics_dict.get('learn', {})
             validation_metrics = metrics_dict.get('validation', {})
             df_learn = pd.DataFrame(learn_metrics, index=[model_name])
             df_valid = pd.DataFrame(validation_metrics, index=[model_name])
             df_learn.columns = [col for col in df_learn.columns]
             df_valid.columns = [col for col in df_valid.columns]
             d = {'Train' : df_learn, 'Test' : df_valid}
             df_concat = pd.concat(d.values(), axis=1, keys=d.keys())
             if df is not None:
                  df_concat = pd.concat([df, df_concat], axis=0)
             return df_concat
In [533... losses = ['RMSE', 'QueryRMSE', 'PairLogit', 'YetiRank']
In [534...
         result_df = None
         for loss_func in tqdm(losses):
             metrics = train_ranker(loss_func)
             if result_df is None:
                  result_df = dict_to_dataframe(metrics, loss_func)
             else:
                  result_df = dict_to_dataframe(metrics, loss_func, result_df)
                         | 0/4 [00:00<?, ?it/s]
           0%|
         C:\Users\ztimu\anaconda3\lib\site-packages\catboost\core.py:6219: RuntimeWarning: Regres
         sion loss ('RMSE') ignores an important ranking parameter 'group_id'
           warnings.warn("Regression loss ('{}') ignores an important ranking parameter 'group_i
         d'".format(loss_function), RuntimeWarning)
         Метрики качества для разных loss функции
In [600... result_df.index.name = 'CatBoostRanker'
```

In [601... | np.round(result_df['Train'][['MAP:top=5', 'PrecisionAt:top=5']], 2)

```
CatBoostRanker
                     RMSE
                                   0.23
                                                     0.19
                                   0.17
                                                     0.15
                QueryRMSE
                   PairLogit
                                   0.11
                                                     0.11
                   YetiRank
                                   0.19
                                                     0.16
           np.round(result_df['Test'][['NDCG:top=10;type=Base', 'PFound', 'NDCG:top=5;type=Base',
                             NDCG:top=10;type=Base PFound NDCG:top=5;type=Base MAP:top=5 PrecisionAt:top=5
Out[602]:
            CatBoostRanker
                     RMSE
                                                        0.68
                                                                                           0.11
                                                                                                             0.10
                                               0.48
                                                                               0.48
                QueryRMSE
                                               0.50
                                                        0.68
                                                                               0.48
                                                                                           0.12
                                                                                                             0.10
                   PairLogit
                                               0.49
                                                        0.66
                                                                               0.47
                                                                                           0.10
                                                                                                             0.10
                   YetiRank
                                                                               0.50
                                               0.50
                                                        0.69
                                                                                           0.13
                                                                                                             0.11
```

Корректность: подадим на вход неинформативные данные.

MAP:top=5 PrecisionAt:top=5

Out[601]:

```
In [566...
          probs = y_train.value_counts().values / y_train.value_counts().sum()
In [567...
         probs
          array([0.51606493, 0.32253527, 0.13585451, 0.0179223 , 0.00762299])
Out[567]:
In [582...
         X_df_dummy = np.random.random(size=(211859, 35))
         y_{dummy} = np.random.choice([0, 0.25, 0.5, 0.75, 1], p=probs, replace=True, size=211859)
         X_df_dummy = pd.DataFrame(X_df_dummy).rename(columns={30: 'feature_95', 31: 'feature_96'
In [583...
         for feat in cat_feats:
In [584...
              X_df_dummy[feat] = sps.bernoulli.rvs(size=211859, p=0.5)
          dummy = Pool(
In [586...
              data=X_df_dummy,
              label=y_dummy,
              group_id=Q_train,
              cat_features=np.array(cat_data.columns)
          parameters['loss_function'] = 'QueryRMSE'
 In [ ]:
          parameters['train_dir'] = 'QueryRMSE'
          model = CatBoostRanker(**parameters)
          model.fit(dummy, eval_set=test, plot=False, use_best_model=True)
In [596...
         model.best_score_['validation']
          {'NDCG:top=10;type=Base': 0.3308435636209059,
Out[596]:
            'PFound': 0.5481857128359304,
            'NDCG:top=5;type=Base': 0.31221416099814264,
            'QueryRMSE': 0.19102692323384216,
            'MAP:top=5': 0.0471472222222221,
            'PrecisionAt:top=5': 0.04700000000000014}
```

При информативном входе NDCG:top=5;type=Base=0.5

Подход 2: Отбор признаков

Использовать one-hot проблематично для категориальных, потому что каждая фича будет закодирована как 0/1, и подача ее в линейную регрессию не позволит выбрать категориальную переменную в целом. Конечно, приблизительно можно брать сумму или еще что-то другое (они хотябы сонаправлены);

Попробуем использовать target encoding

```
from sklearn.linear_model import Lasso
In [603...
           import statsmodels.api as sm
          data = pd.read_csv('intern_task.csv')
   [659...
          data = data.drop(columns=useless_feats)
In
   [660...
   [661...
          max_rank = np.max(data['rank'])
           data['rank'] /= max_rank
          Q_test_indexes = np.random.choice(data['query_id'].unique(), size=200, replace=False)
   [607...
           Q_train_indexes = np.array([i for i in data['query_id'].unique() if i not in Q_test_inde
In [611...
          X_df = data.loc[np.where(data['query_id'].isin(Q_train_indexes))]
          for feat in cat_feats:
In [613...
               means = X_df.groupby(feat)['rank'].mean()
               X_df[f'encoded_{feat}'] = X_df[feat].map(means)
          X_df = X_df.drop(columns=cat_feats)
          X_df.head()
In [614...
              rank query_id feature_0 feature_1 feature_2 feature_3 feature_4
                                                                            feature_5 feature_6
                                                                                                feature_7
Out[614]:
              0.00
                         10
                                  1.0
                                            0.0
                                                     1.0
                                                               3.0
                                                                             0.333333
                                                                                                0.333333
                                                                        3.0
                                                                                           0.0
              0.25
                         10
                                  3.0
                                            0.0
                                                               0.0
                                                     3.0
                                                                        3.0
                                                                             1.000000
                                                                                           0.0
                                                                                                1.000000
              0.00
                                  3.0
                                            0.0
                                                     2.0
                                                               0.0
                         10
                                                                        3.0
                                                                             1.000000
                                                                                           0.0
                                                                                                0.666667
              0.25
                         10
                                  3.0
                                            0.0
                                                     3.0
                                                               0.0
                                                                        3.0
                                                                             1.000000
                                                                                           0.0
                                                                                                1.000000
              0.50
                         10
                                  3.0
                                            0.0
                                                     3.0
                                                               1.0
                                                                        3.0
                                                                             1.000000
                                                                                                1.000000
                                                                                           0.0
           5 rows × 142 columns
In [618...
          X_df.drop(columns=['rank', 'query_id']).shape
           (211337, 140)
Out[618]:
```

```
model = sm.OLS(X_df['rank'], X_df.drop(columns=['rank', 'query_id']))
In [619...
         results = model.fit()
         print(results.summary())
```

OLS Regression Results

______ Dep. Variable: R-squared (uncentered): 0.480 rank Adj. R-squared (uncentered): Model: 0LS 0.480 Method: Least Squares F-statistic: 1436. Thu, 25 Apr 2024 Date: Prob (F-statistic): 0.00 Time: 02:47:47 Log-Likelihood: 46992. No. Observations: 211337 AIC: -9.371e+04 Df Residuals: 211201 BIC: -9.232e+04

Df Model: 136

Df Model: Covariance Type:	136 nonrobust					
=======================================		=========	.=======	.=======		========
	coef	std err	t	P> t	[0.025	0.975]
feature_0	-0.0437	0.008	-5.728	0.000	-0.059	-0.029
feature_1	0.0064	0.004	1.449	0.147	-0.002	0.015
feature_2	-0.0097	0.003	-2.970	0.003	-0.016	-0.003
feature_3	0.0379	0.007	5.419	0.000	0.024	0.052
feature_4	0.0564	0.008	7.200	0.000	0.041	0.072
feature_5	-0.0227	0.023	-1.000	0.317	-0.067	0.022
feature_6	0.0519	0.020	2.608	0.009	0.013	0.091
feature_7	0.0680	0.011	6.225	0.000	0.047	0.089
feature_8	7.8717	8.706	0.904	0.366	-9.192	24.935
feature_9	-0.0711	0.023	-3.082	0.002	-0.116	-0.026
feature_10	-0.4636	0.513	-0.903	0.366	-1.470	0.542
feature_11	-0.4637	0.513	-0.903	0.366	-1.470	0.542
feature_12	-0.4636	0.513	-0.903	0.366	-1.470	0.542
feature_13	-0.4661	0.513	-0.908	0.364	-1.472	0.540
feature_14	0.4636	0.513	0.903	0.366	-0.542	1.470
feature_15	-0.0080	0.005	-1.566	0.117	-0.018	0.002
feature_16	-0.0067	0.001	-9.539	0.000	-0.008	-0.005
feature_17	0.0054	0.001	8.797	0.000	0.004	0.007
feature_18	0.0007	0.000	1.747	0.081	-8.96e-05	0.002
feature_19	0.0081	0.005	1.581	0.114	-0.002	0.018
feature_20	-0.3830	0.424	-0.904	0.366	-1.213	0.447
feature_21	0.7521	0.805	0.934	0.350	-0.825	2.330
feature_22	0.7274	0.805	0.904	0.366	-0.850	2.305
feature_23	0.7025	0.805	0.873	0.383	-0.875	2.280
feature_24	-0.7281	0.805	-0.905	0.366	-2.306	0.849
feature_25	-0.0066	0.002	-3.068	0.002	-0.011	-0.002
feature_26	0.0165	0.012	1.347	0.178	-0.008	0.041
feature_27	-0.0165	0.006	-2.840	0.005	-0.028	-0.005
feature_28	-0.0364	0.020	-1.861	0.063	-0.075	0.002
feature_29	0.0085	0.002	3.998	0.000	0.004	0.013
feature_30	0.0067	0.002	3.916	0.000	0.003	0.010
feature_31	-0.0258	0.010	-2.714	0.007	-0.044	-0.007
feature_32	-0.0096	0.004	-2.407	0.016	-0.017	-0.002
feature_33	0.0050	0.014	0.349	0.727	-0.023	0.033
feature_34	-0.0062	0.002	-3.650	0.000	-0.010	-0.003
feature_35	-0.0039	0.004	-0.904	0.366	-0.012	0.005
feature_36	-1689.1257	1868.135	-0.904	0.366	-5350.623	1972.372
feature_37	-1689.0766	1868.135	-0.904	0.366	-5350.574	1972.421
feature_38	-1689.0770	1868.134	-0.904	0.366	-5350.574	1972.420
feature_39	1689.1297	1868.135	0.904	0.366	-1972.368	5350.627
feature_40	4.793e-05	1.7e-05	2.825	0.005	1.47e-05	8.12e-05
feature_41	0.0013	0.001	2.434	0.015	0.000	0.002
feature_42	0.0003	9.7e-05	3.272	0.001	0.000	0.001
feature_43	-0.0100	0.015	-0.674	0.500	-0.039	0.019
feature_44	-4.875e-05	1.69e-05	-2.893	0.004	-8.18e-05	-1.57e-05

feature_45	0.1960	0.043	4.553	0.000	0.112	0.280
feature_46	-0.0406	0.015	-2.682	0.007	-0.070	-0.011
feature_47	0.0269	0.009	2.870	0.004	0.009	0.045
feature_48	-0.0002	0.000	-0.860	0.390	-0.001	0.000
feature_49	-0.4213	0.054	-7.823	0.000	-0.527	-0.316
feature_50	-0.3035	0.188	-1.615	0.106	-0.672	0.065
feature_51	0.0379	0.035	1.091	0.275	-0.030	0.106
feature_52	0.0237	0.027	0.892	0.373	-0.028	0.076
feature_53	0.4043	0.143	2.829	0.005	0.124	0.684
feature_54	-0.5264	0.217	-2.421	0.015	-0.953	-0.100
feature_55	-0.8555 0.0308	0.174	-4.918	0.000	-1.196	-0.515
feature_56 feature_57	0.0009	0.023 0.021	1.364 0.045	0.172 0.964	-0.013 -0.040	0.075 0.042
feature_58	-0.5969	0.102	-5.850	0.000	-0.797	-0.397
feature_59	0.8781	0.197	4.459	0.000	0.492	1.264
feature_60	0.8238	0.346	2.380	0.017	0.145	1.502
feature_61	-0.0104	0.045	-0.233	0.815	-0.098	0.077
feature_62	-0.0697	0.041	-1.691	0.091	-0.151	0.011
feature_63	0.4416	0.189	2.340	0.019	0.072	0.812
feature_66	0.0647	0.073	0.884	0.377	-0.079	0.208
feature_67	0.0910	0.066	1.372	0.170	-0.039	0.221
feature_68	5.9867	1.050	5.701	0.000	3.928	8.045
feature_69	-6.5696	1.034	-6.351	0.000	-8.597	-4.542
feature_70	0.0001	0.001	0.272	0.785	-0.001	0.001
feature_71 feature_73	-0.0032 0.0010	0.001 0.001	-3.942 0.892	0.000 0.373	-0.005 -0.001	-0.002 0.003
feature_74	-0.0002	0.001	-0.348	0.728	-0.001	0.001
feature_75	-0.0028	0.001	-5.126	0.000	-0.004	-0.002
feature_76	-0.0043	0.002	-2.778	0.005	-0.007	-0.001
feature_77	-0.0010	0.001	-1.297	0.195	-0.003	0.001
feature_78	-0.0025	0.002	-1.523	0.128	-0.006	0.001
feature_79	0.0024	0.001	4.605	0.000	0.001	0.003
feature_80	0.0002	0.000	0.510	0.610	-0.001	0.001
feature_81	0.0038	0.001	3.260	0.001	0.002	0.006
feature_82	0.0026	0.001	4.551	0.000	0.002	0.004
feature_83	0.0077	0.001	5.994	0.000	0.005	0.010
feature_84	-0.0004	0.000	-1.027	0.304	-0.001	0.000
feature_85 feature_86	-0.0030 0.0002	0.001 0.003	-2.378 0.079	0.017 0.937	-0.005 -0.005	-0.001 0.006
feature_87	-0.0082	0.003	-5.195	0.000	-0.003	-0.005
feature_88	-0.0117	0.003	-4.147	0.000	-0.017	-0.006
feature_89	0.0036	0.001	2.934	0.003	0.001	0.006
feature_90	-1.912e-06	1.18e-06	-1.620	0.105	-4.22e-06	4.01e-07
feature_91	-2.023e-05	8.3e-06	-2.437	0.015	-3.65e-05	-3.96e-06
feature_92	-6.184e-06	2.49e-06	-2.480	0.013	-1.11e-05	-1.3e-06
feature_93	-0.0002	0.000	-1.768	0.077	-0.000	2.39e-05
feature_94	1.899e-06	1.18e-06	1.616	0.106	-4.05e-07	4.2e-06
feature_101	-0.0792	0.013	-6.292	0.000	-0.104	-0.055
feature_102	-0.0677	0.007	-10.060	0.000	-0.081	-0.055
feature_103 feature_104	-0.0571 0.0029	0.009 0.014	-6.149 0.206	0.000 0.837	-0.075 -0.025	-0.039 0.030
feature_104	0.0029	0.000	1.015	0.310	-0.023	0.001
feature_106	0.0016	0.001	3.064	0.002	0.001	0.003
feature_107	0.0016	0.000	6.268	0.000	0.001	0.002
feature_108	0.0008	0.001	0.892	0.372	-0.001	0.002
feature_109	0.0005	0.000	1.264	0.206	-0.000	0.001
feature_110	-0.0042	0.002	-2.431	0.015	-0.008	-0.001
feature_111	-0.0025	0.001	-3.178	0.001	-0.004	-0.001
feature_112	0.0059	0.001	5.171	0.000	0.004	0.008
feature_113	0.0195	0.002	9.994	0.000	0.016	0.023
feature_114	0.0249	0.002	13.194	0.000	0.021	0.029
feature_115	0.0090	0.002	5.125	0.000	0.006	0.012
feature_116 feature_117	-0.0007 -0.0064	0.000 0.001	-2.326 -11.731	0.020 0.000	-0.001 -0.008	-0.000 -0.005
feature_117	-0.0041	0.001	-11.731 -5.674	0.000	-0.006	-0.003
feature_119	-0.0128	0.001	-6.809	0.000	-0.000	-0.009
	3.3123	0.002	0.000	5.000	J. U.	3.500

```
feature_120
                      -0.0008
                                  0.002
                                            -0.460
                                                        0.645
                                                                   -0.004
                                                                                0.003
                                                        0.000
feature_121
                      0.0032
                                  0.001
                                             5.030
                                                                    0.002
                                                                                0.004
feature_122
                      0.0001
                                  0.001
                                             0.158
                                                        0.874
                                                                   -0.002
                                                                                0.002
feature_123
                     -0.0137
                                  0.001
                                           -10.010
                                                        0.000
                                                                   -0.016
                                                                               -0.011
                                  0.002
                                                        0.000
feature_124
                     -0.0134
                                            -6.837
                                                                   -0.017
                                                                               -0.010
                                                        0.000
feature_125
                     -0.0063
                                  0.000
                                           -15.428
                                                                   -0.007
                                                                               -0.005
feature_126
                      0.0004
                               4.98e-05
                                             7.720
                                                        0.000
                                                                    0.000
                                                                                0.000
feature_127
                   -3.834e-10
                               1.35e-10
                                            -2.837
                                                        0.005
                                                                -6.48e-10
                                                                            -1.19e-10
                               5.25e-05
                                            24.506
                                                        0.000
feature_128
                      0.0013
                                                                    0.001
                                                                                0.001
feature_129
                   7.116e-07
                               2.21e-08
                                            32.150
                                                        0.000
                                                                 6.68e-07
                                                                             7.55e-07
feature_130
                   1.226e-07
                               2.54e-08
                                             4.821
                                                        0.000
                                                                 7.28e-08
                                                                             1.72e-07
feature_131
                   6.569e-05
                               1.68e-05
                                             3.916
                                                        0.000
                                                                 3.28e-05
                                                                             9.86e-05
feature_132
                     -0.0003
                               1.22e-05
                                           -21.267
                                                        0.000
                                                                   -0.000
                                                                               -0.000
                                                        0.000
                                                                 3.21e-08
feature_133
                   5.054e-08
                               9.38e-09
                                             5.386
                                                                             6.89e-08
feature_134
                  -6.209e-08
                               2.25e-08
                                            -2.754
                                                        0.006
                                                                -1.06e-07
                                                                            -1.79e-08
feature_135
                  -5.161e-11
                               1.51e-10
                                            -0.342
                                                        0.732
                                                                -3.47e-10
                                                                             2.44e-10
                                                        0.094
feature_136
                     -0.0792
                                  0.047
                                            -1.673
                                                                   -0.172
                                                                                0.014
feature_137
                     -0.0119
                                  0.014
                                            -0.867
                                                        0.386
                                                                   -0.039
                                                                                0.015
feature_138
                     -0.0002
                                  0.001
                                            -0.360
                                                        0.719
                                                                   -0.001
                                                                                0.001
                                             0.105
                                                        0.916
feature_139
                      0.0019
                                  0.018
                                                                   -0.033
                                                                                0.037
feature_140
                      0.1999
                                  0.394
                                             0.507
                                                        0.612
                                                                   -0.572
                                                                                0.972
                      1.2725
                                  0.392
                                             3.249
                                                        0.001
                                                                    0.505
                                                                                2.040
feature_141
feature_142
                      0.7284
                                  0.805
                                             0.905
                                                        0.365
                                                                   -0.849
                                                                                2.306
                  -1689.1319
feature_143
                               1868.135
                                            -0.904
                                                        0.366
                                                                -5350.630
                                                                             1972.366
                                                        0.000
encoded_feature_95
                      0.7522
                                  0.173
                                             4.352
                                                                    0.413
                                                                                1.091
                     -0.1287
                                  0.098
                                            -1.316
                                                        0.188
                                                                   -0.320
                                                                                0.063
encoded_feature_96
encoded_feature_97
                      0.3932
                                  0.048
                                             8.277
                                                        0.000
                                                                    0.300
                                                                                0.486
encoded_feature_98
                      0.4344
                                  0.111
                                             3.923
                                                        0.000
                                                                    0.217
                                                                                0.651
encoded_feature_99
                     -0.3024
                                  0.154
                                            -1.963
                                                        0.050
                                                                               -0.000
                                                                   -0.604
_______
                           33681.060
                                       Durbin-Watson:
Omnibus:
                                                                        1.836
Prob(Omnibus):
                               0.000
                                       Jarque-Bera (JB):
                                                                    56909.588
```

Skew: 1.061 Prob(JB): 0.00 4.400 Kurtosis: Cond. No. 1.06e+16 _______

Notes:

- [1] R² is computed without centering (uncentered) since the model does not contain a con
- [2] Standard Errors assume that the covariance matrix of the errors is correctly specifi
- [3] The smallest eigenvalue is 1.84e-14. This might indicate that there are strong multicollinearity problems or that the design matrix is singular.

Применим МПГ. Для 48 признаков гипотеза о незначимости отвергается. Попробуем обучить модель на них.

```
from statsmodels.stats.multitest import multipletests
In [662...
           (multipletests(results.pvalues)[0] == True).sum()
            48
Out[662]:
           indexes = np.where(multipletests(results.pvalues)[0] == True)
In [663...
           feats = data.drop(columns=['rank', 'query_id']).columns[feats[0]]
           feats
In [664...
            Index(['feature_0', 'feature_3', 'feature_4', 'feature_7', 'feature_16',
Out[664]:
                    'feature_17', 'feature_29', 'feature_30', 'feature_34', 'feature_45',
                    'feature_49', 'feature_55', 'feature_58', 'feature_59', 'feature_68',
                    'feature_69', 'feature_71', 'feature_75', 'feature_79', 'feature_82', 'feature_83', 'feature_87', 'feature_88', 'feature_95', 'feature_96',
```

```
'feature_116',
                                                  'feature_118', 'feature_119',
                  'feature_114',
                  'feature_120', 'feature_121', 'feature_123', 'feature_124',
                  'feature_125', 'feature_126', 'feature_127', 'feature_128',
                  'feature_139', 'feature_141', 'feature_142'],
                 dtype='object')
In [665...
          data[list(set(cat_feats) & set(feats))] = data[list(set(cat_feats) & set(feats))].astype
          data.head()
             rank query_id feature_0 feature_1 feature_2 feature_3 feature_4 feature_5 feature_6 feature_7
Out[665]:
             0.00
                                         0.0
                                                            3.0
                                                                         0.333333
                                                                                           0.333333
                        10
                                1.0
                                                   1.0
                                                                     3.0
                                                                                       0.0
              0.25
                                         0.0
                                                                         1.000000
                                                                                           1.000000
                        10
                                3.0
                                                   3.0
                                                            0.0
                                                                     3.0
           2
              0.00
                        10
                                3.0
                                         0.0
                                                   2.0
                                                            0.0
                                                                     3.0
                                                                         1.000000
                                                                                       0.0
                                                                                           0.666667
              0.25
                        10
                                3.0
                                         0.0
                                                   3.0
                                                            0.0
                                                                     3.0
                                                                         1.000000
                                                                                       0.0
                                                                                           1.000000
              0.50
                        10
                                3.0
                                         0.0
                                                   3.0
                                                            1.0
                                                                     3.0
                                                                         1.000000
                                                                                       0.0
                                                                                           1.000000
          5 rows × 142 columns
In [666...
          Y_data = data['rank']
          Q_data = data['query_id']
          X_data = data.drop(columns=['rank', 'query_id'])
          Обучение
In [667...
          Q_test_indexes = np.random.choice(Q_data.unique(), size=200, replace=False)
          Q_train_indexes = np.array([i for i in Q_data.unique() if i not in Q_test_indexes])
          assert(Q_train_indexes.shape[0] == 1800 and Q_test_indexes.shape[0] == 200)
          X_train_df = X_data.loc[np.where(Q_data.isin(Q_train_indexes))]
In [668...
          X_test_df = X_data.loc[np.where(Q_data.isin(Q_test_indexes))]
          y_train = Y_data.loc[np.where(Q_data.isin(Q_train_indexes))]
          y_test = Y_data.loc[np.where(Q_data.isin(Q_test_indexes))]
          Q_train = Q_data.loc[np.where(Q_data.isin(Q_train_indexes))]
          Q_test = Q_data.loc[np.where(Q_data.isin(Q_test_indexes))]
          X_train_df.columns = X_train_df.columns.astype(str)
In [669...
          X_test_df.columns = X_test_df.columns.astype(str)
          train = Pool(
In [671...
              data=X_train_df,
              label=y_train,
              group_id=Q_train,
              cat_features=np.array(list(set(cat_feats) & set(feats)))
          test = Pool(
              data=X_test_df,
              label=y_test,
              group_id=Q_test,
              cat_features=np.array(list(set(cat_feats) & set(feats)))
          losses = ['RMSE', 'QueryRMSE']
In [672...
```

'feature_109',

'feature_110',

'feature_112',

'feature_113'

```
result_df_2 = None
In [673...
          for loss_func in tqdm(losses):
              metrics = train_ranker(loss_func)
              if result_df_2 is None:
                  result_df_2 = dict_to_dataframe(metrics, loss_func)
              else:
                  result_df_2 = dict_to_dataframe(metrics_dict, loss_func, result_df_2)
            0%|
                         | 0/2 [00:00<?, ?it/s]
         C:\Users\ztimu\anaconda3\lib\site-packages\catboost\core.py:6219: RuntimeWarning: Regres
         sion loss ('RMSE') ignores an important ranking parameter 'group_id'
           warnings.warn("Regression loss ('{}') ignores an important ranking parameter 'group_i
         d'".format(loss_function), RuntimeWarning)
         np.round(result_df_2['Test'][['NDCG:top=10;type=Base', 'PFound', 'NDCG:top=5;type=Base'
In [674...
                  NDCG:top=10;type=Base PFound NDCG:top=5;type=Base MAP:top=5 PrecisionAt:top=5
Out[674]:
            RMSE
                                  0.57
                                          0.75
                                                              0.57
                                                                        0.17
                                                                                        0.15
           Model1
                                  0.50
                                          0.68
                                                              0.48
                                                                        0.12
                                                                                        0.10
```

Совсем без обработки

```
data = pd.read_csv('intern_task.csv')
In [675...
         data = data.drop(columns=useless_feats)
In [676...
In [677... Y_data = data['rank']
         Q_data = data['query_id']
         X_data = data.drop(columns=['rank', 'query_id'])
         Q_test_indexes = np.random.choice(Q_data.unique(), size=200, replace=False)
In [680...
         Q_train_indexes = np.array([i for i in Q_data.unique() if i not in Q_test_indexes])
         assert(Q_train_indexes.shape[0] == 1800 and Q_test_indexes.shape[0] == 200)
         X_train_df = X_data.loc[np.where(Q_data.isin(Q_train_indexes))]
         X_test_df = X_data.loc[np.where(Q_data.isin(Q_test_indexes))]
         y_train = Y_data.loc[np.where(Q_data.isin(Q_train_indexes))]
         y_test = Y_data.loc[np.where(Q_data.isin(Q_test_indexes))]
         y_test /= max(y_test)
         y_train /= max(y_train)
         Q_train = Q_data.loc[np.where(Q_data.isin(Q_train_indexes))]
         Q_test = Q_data.loc[np.where(Q_data.isin(Q_test_indexes))]
         train = Pool(
             data=X_train_df,
             label=y_train,
             group_id=Q_train
         test = Pool(
             data=X_test_df,
             label=y_test,
             group_id=Q_test
```

```
In [681... losses = ['RMSE', 'QueryRMSE']
```

Выводы:

С удалением неинформативных признаков, добав. катег. признаки. РСА 30 компонент.

In [684 np	np.round(result_df['Test'][['NDCG:top=10;type=Base', 'PFound', 'NDCG:top=5;type=Base',							
Out[684]:		NDCG:top=10;type=Base	PFound	NDCG:top=5;type=Base	MAP:top=5	PrecisionAt:top=5		
С	atBoostRanker							
	RMSE	0.48	0.68	0.48	0.11	0.10		
	QueryRMSE	0.50	0.68	0.48	0.12	0.10		
	PairLogit	0.49	0.66	0.47	0.10	0.10		
	YetiRank	0.50	0.69	0.50	0.13	0.11		

С удалением неинформативных признаков, добав. катег. признаки.

Отбор признаков через ttest.

In [685	np.round(result_df_2['Test'][['NDCG:top=10;type=Base', 'PFound', 'NDCG:top=5;type=Base						
Out[685]:		NDCG:top=10;type=Base	PFound	NDCG:top=5;type=Base	MAP:top=5	PrecisionAt:top=5	
	RMSE	0.57	0.75	0.57	0.17	0.15	
	Model1	0.50	0.68	0.48	0.12	0.10	

С удалением неинформативных признаков.

```
np.round(result_df_3['Test'][['NDCG:top=10;type=Base', 'PFound', 'NDCG:top=5;type=Base',
In [686...
                   NDCG:top=10;type=Base PFound NDCG:top=5;type=Base MAP:top=5 PrecisionAt:top=5
Out[686]:
             RMSE
                                     0.58
                                             0.77
                                                                   0.59
                                                                              0.20
                                                                                               0.18
            Model1
                                     0.50
                                             0.68
                                                                   0.48
                                                                              0.12
                                                                                               0.10
```